

Класифікація "Fake vs True" на базі Two-Tier архітектури в українських новинах

Виконав студент групи ПМІД-11
Петренко Дмитро

Бачення та мета проєкту

Від статистики до семантики

Мета проєкту — створити стійку NLP-систему, здатну розрізняти не лише примітивний клікбейт, а й складні семантичні маніпуляції у воєнний час.

- **Tier 1:** Миттєва фільтрація на базі ML.
- **Tier 2:** Глибокий семантичний аналіз через LLM.
- **Information Extraction:** Витягнення контексту (осіб та локацій).



Аналіз корпусу даних (10 000 записів)



Виклики розмітки

Використано очищений датасет `processed_v2`, що містить україномовні новини, військові зведення та пропагандистські матеріали.

Дисбаланс класів:

- True News: 76.7%
- Fake/Propaganda: 23.3%

Дворівнева архітектура (Two-Tier)



Tier 1: Fast Filter

TF-IDF + LinearSVC. Відсіювання
клікбейту та емоційного спаму за
частотою символів.



Tier 2: Deep Flow

Stateful LLM Agent (Llama 3.1).
Семантична перевірка фактів та логіки
тверджень.



Validation Layer

JSON Schema + Repair Loop.
Гарантована цілісність та
структурованість виводу.

Tier 1: Статистичне ядро системи

92%
Accuracy (SVM)

Сила символьних n-грам

Використання **char n-grams (3-5)** замість слів дозволило моделі ігнорувати помилки та ефективно розпізнавати суржик, що є маркером пропаганди.

- Macro-F1 Score: **0.8903**
- Стійкість до одруківок та варіацій написання.
- Балансування ваг для міноритарного класу (Fake).

Information Extraction: Hybrid NER

Проблема: Out-of-Domain

Стандартні моделі spaCy часто пропускають українські військові аббревіатури (ЗСУ, ППО, ГШ) та специфічні назви техніки.

Рішення: Гібридні правила

Інтеграція EntityRuler та Regex дозволила підняти Recall сутностей до **0.93**. Тепер система чітко бачить суб'єктів новини.

Tier 2: Семантичний розбір

Вирішення "Domain Shift"

Класичний ML сліпий до змісту. Фраза "Зеленський віддав території" виглядає для SVM як True через знайомі слова.

Tier 2 використовує LLM Reasoning для аналізу **логічної цілісності** повідомлення. Агент перевіряє факти, посилаючись на внутрішні знання та контекст офіційних джерел.



Стійкість та автоматичне відновлення



Schema Control

Жорстка валідація JSON-схеми гарантує, що дані готові до експорту в БД.



Repair Loop

Автономний цикл виправлення помилок LLM (у разі невалідного формату).



Fallback Logic

Запуск ручної перевірки для кейсів з низькою впевненістю (Confidence < 0.5).

Порівняння метрик: Baseline vs Final



Фінальне рішення Tier 1 демонструє приріст Macro-F1 на 4 пункти відносно бейзлайну, а Tier 2 повністю нівелює помилки семантичного розбору.


Кейси: Аналіз та виправлення помилок

Вхідний текст (Приклад)	Tier 1 (SVM)	Tier 2 (LLM Flow)	Статус
"Терміново! Шок виплата 5000 грн"	FAKE (100%)	– (skipped)	✓ Успіх
"Україна програла війну"	TRUE (Error)	FAKE (Reasoning)	✓ Виправлено
"ЗСУ відбили атаку під Києвом"	TRUE (95%)	– (skipped)	✓ Успіх

Висновки та перспективи

Підсумки проєкту

- **Інженерна стійкість:** Система не падає при помилках LLM завдяки Flow.
- **Масштабованість:** Tier 1 дозволяє обробляти великі потоки даних з мінімальними витратами.
- **Доменна адаптація:** Гібридний NER успішно працює з військовою лексикою.



Питання?

Дякую за увагу! Весь код та документація доступні в репозиторії.

 github.com/dmytroslav/NLP_Course